

Penyebaran Data

Tim Ajar Statistik Komputasi

2023/2024

Outlines

Definisi Penyebaran Data

Pengukuran Penyebaran Data

Shifting dan Scaling



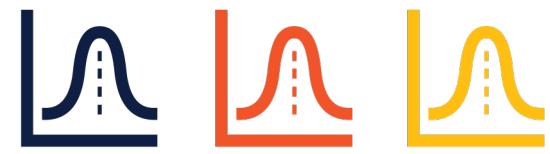
Apa itu penyebaran data?

Apa yang dimaksud dengan menyebar? Digunakan untuk apa?

Penyebaran Data

Definisi

- Nilai yang menggambarkan jarak data dari pusat data
- Digunakan untuk mengukur, seberapa baik nilai pemusatan data
- Untuk menentukan nilai pusat data yang paling relevan dengan kondisi data



Pengukuran Penyebaran Data #1

Pengukuran penyebaran data dapat diukur dengan rentang (range) dan interquartile range (IQR). Apa itu?

Rentang (Range)

Nilai Rentang

- Nilai selisih antara amatan terbesar dengan amatan terkecil
- Digunakan untuk penekanan pada nilai ekstrim
- Nilainya dipengaruhi oleh nilai ekstrim (sangat kecil atau sangat besar)

Persamaan

$$rentang = x_{max} - x_{min}$$

Rentang (Range) – Contoh

Nilai Matematika Kelas 12 SMA XYZ

23 56 45 65 59 55 62 54 85 25

Hasil

$$rentang = 85 - 23 = 62$$

Python



```
1 import numpy as np  
2  
3 data = np.array([23, 56, 45, 65, 59, 55, 62, 54, 85, 25])  
4 data_max = max(data)  
5 data_min = min(data)  
6 range = data_max - data_min  
7 print(range)
```

Interquartile Range (IQR)

Kuartil (Quartile)

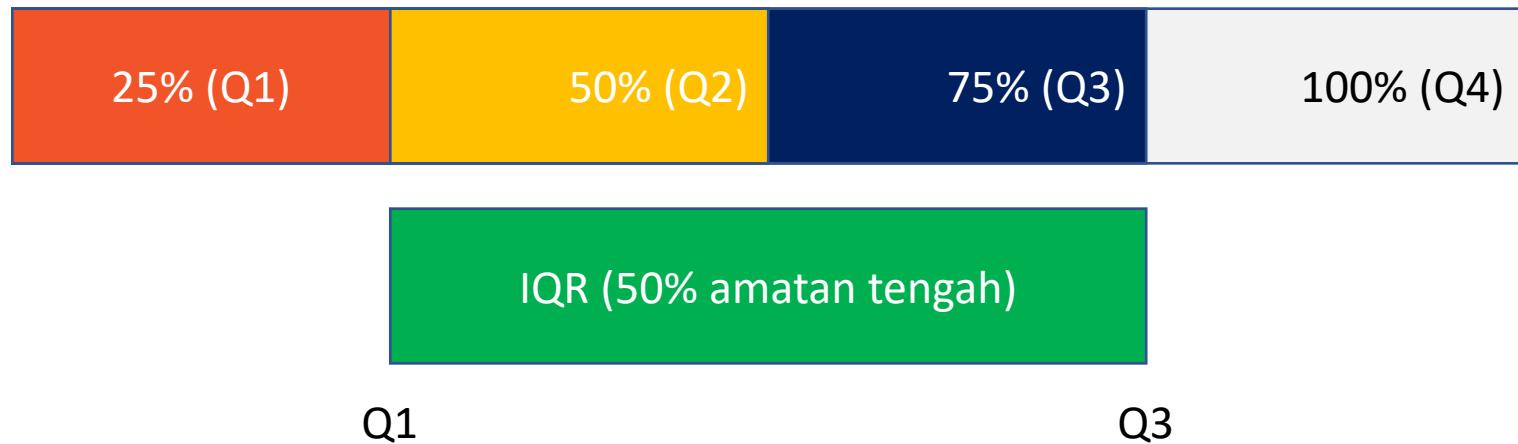
Membagi data kedalam 4 kelompok, 25% pertama data (Q1), 50% data (Q2), 75% data (Q3), dan 100% data (Q4)

Nilai IQR

Nilai yang digunakan untuk mendeskripsikan 50% amatan tengah

Definisi Matematis

$$IQR = Q3 - Q1$$



Bagaimana mendapatkan nilai Q3 dan Q1? (1)

Contoh Kasus 1

23

25

45

54

55

56

59

62

65

85

Q1

$$Q1 = 45$$

Q2

$$Q2 = \frac{55 + 56}{2} = 55.5$$

Q3

$$Q3 = 62$$

$$IQR = 62 - 45 = 17$$

Bagaimana mendapatkan nilai Q3 dan Q1? (3)

Contoh Kasus 2

23 25 **45** 54 55 **55** 56 59 **62** 65 85

Q1

Q2

Q3

Bagaimana mendapatkan nilai Q3 dan Q1? (3)

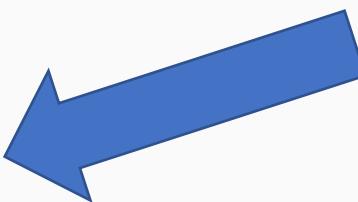
Python

```
1 import numpy as np
2 import pandas as pd
3
4 data_baru = np.array([23, 56, 45, 65, 59, 55, 62, 54, 85, 25, 55])
5 print(pd.DataFrame(data_baru).describe())
6
7 ...
8 Output
9 count    11.000000
10 mean     53.090909
11 std      17.466852
12 min      23.000000
13 25%     49.500000
14 50%     55.000000
15 75%     60.500000
16 max      85.000000
17 ...
```

Mengapa hasil pada Python Pandas berbeda?

```
1 import numpy as np
2 import pandas as pd
3
4 data_baru = np.array([23, 56, 45, 65, 59, 55, 62, 54, 85, 25, 55])
5 print(pd.DataFrame(data_baru).describe())
6 ...
7 ...
8 Output
9 count    11.000000
10 mean     53.090909
11 std      17.466852
12 min      23.000000
13 25%     49.500000
14 50%     55.000000
15 75%     60.500000
16 max     85.000000
17 ...
```

Perhatikan nilai Q1, Q2, dan Q3



Pada Pandas, pendekatan untuk mencari nilai percentil dan quantile (termasuk quartile) yaitu dengan menggunakan nilai **LINEAR INTERPOLATION**

Nilai *linear interpolation* digunakan jika nilai yang dicari berada pada 2 nilai (jumlah data genap)

Nilai linear interpolation didapatkan dari,

$$x_{\text{linear}} = i + (j - i) * \text{fraction}$$

Untuk mendapatkan nilai rata-rata diantara kedua nilai, pada Pandas harus menggunakan nilai 'midpoint' dimana nilainya adalah $(i + j)/2$

Metode perhitungan percentile, quantile, dan quartile pada library-library Python



Contoh pada Numpy, Pandas, dan Scipy

- Linear $\rightarrow i + (j - i) * fraction$ (**digunakan secara default**)
- Lower \rightarrow Nilai i
- Higher \rightarrow Nilai j
- Nearest \rightarrow Nilai i atau j tergantung mana yang terdekat
- Midpoint $\rightarrow (i + j)/2$

Anomali Pada Nilai IQR

Contoh Kasus

30 40 **40** 40 40 **40** 40 40 **40** 40 90

Q1

Q2

Q3

$$IQR = 40 - 40 = 0 \quad ??? \rightarrow$$

Nilai IQR 0 menandakan amatan mempunyai nilai yang identik

Varians (Variance)

Definisi

Nilai yang mendeskripsikan seberapa jauh data menyebar dari nilai mean

Populasi

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$

Sampel

$$S^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Simpangan Baku (*Standard Deviation*) (1)



Definisi

Nilai yang mendeskripsikan seberapa besar variasi data terhadap nilai mean

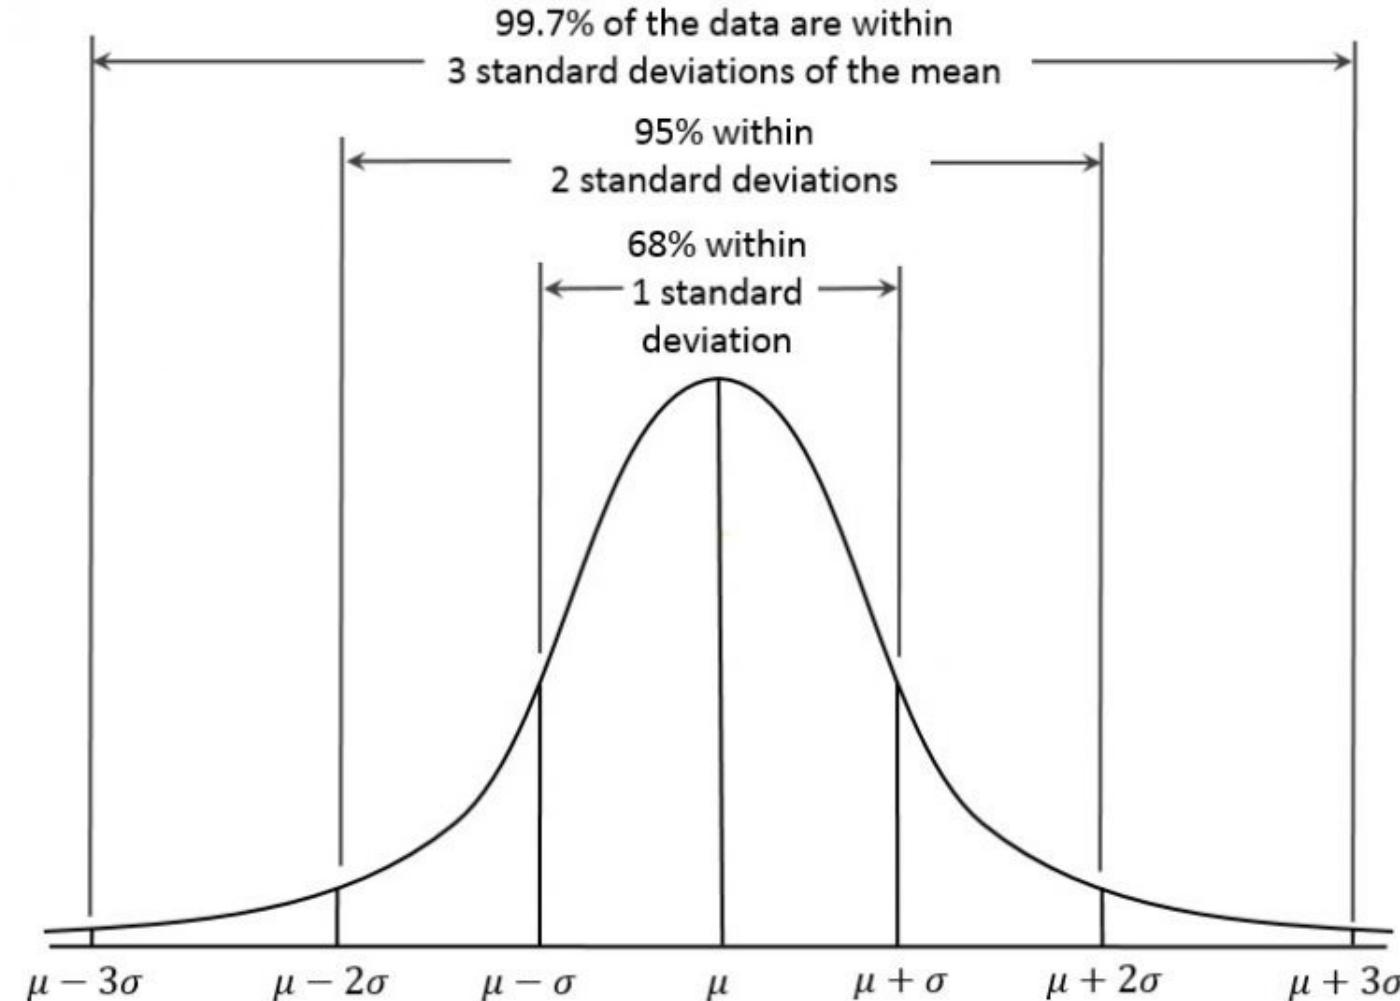
Populasi

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Sampel

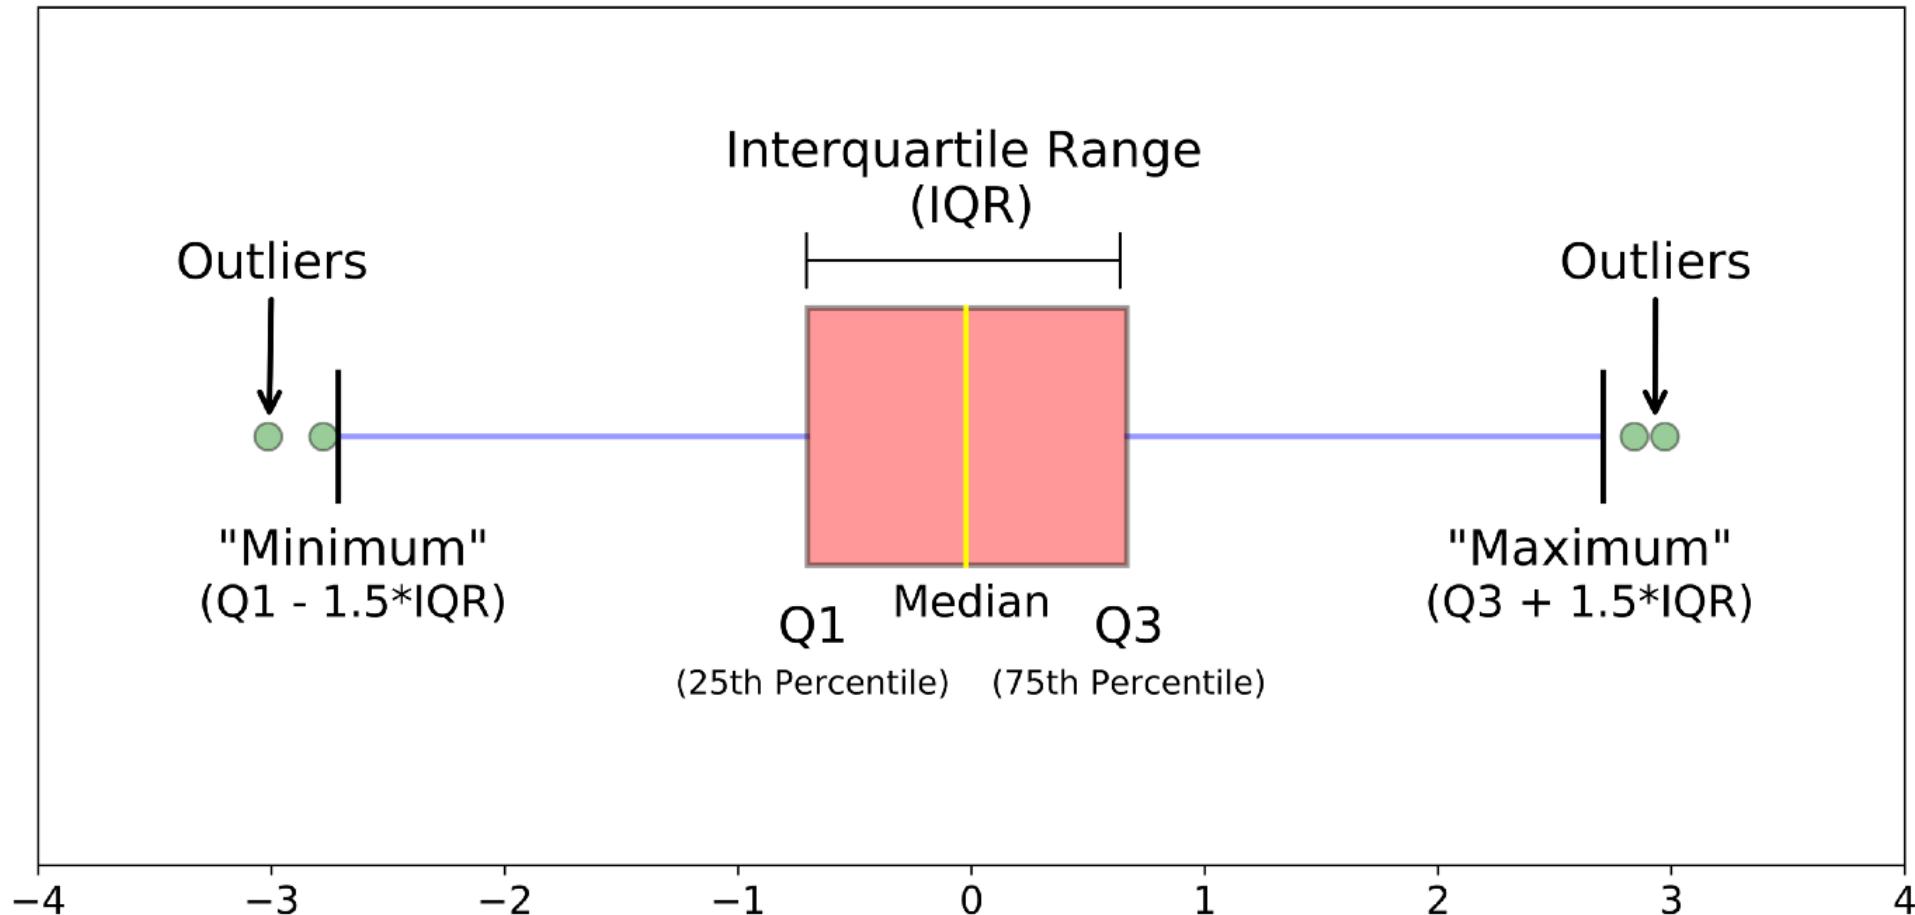
$$S = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}}$$

Simpangan Baku (Standard Deviation) (2)



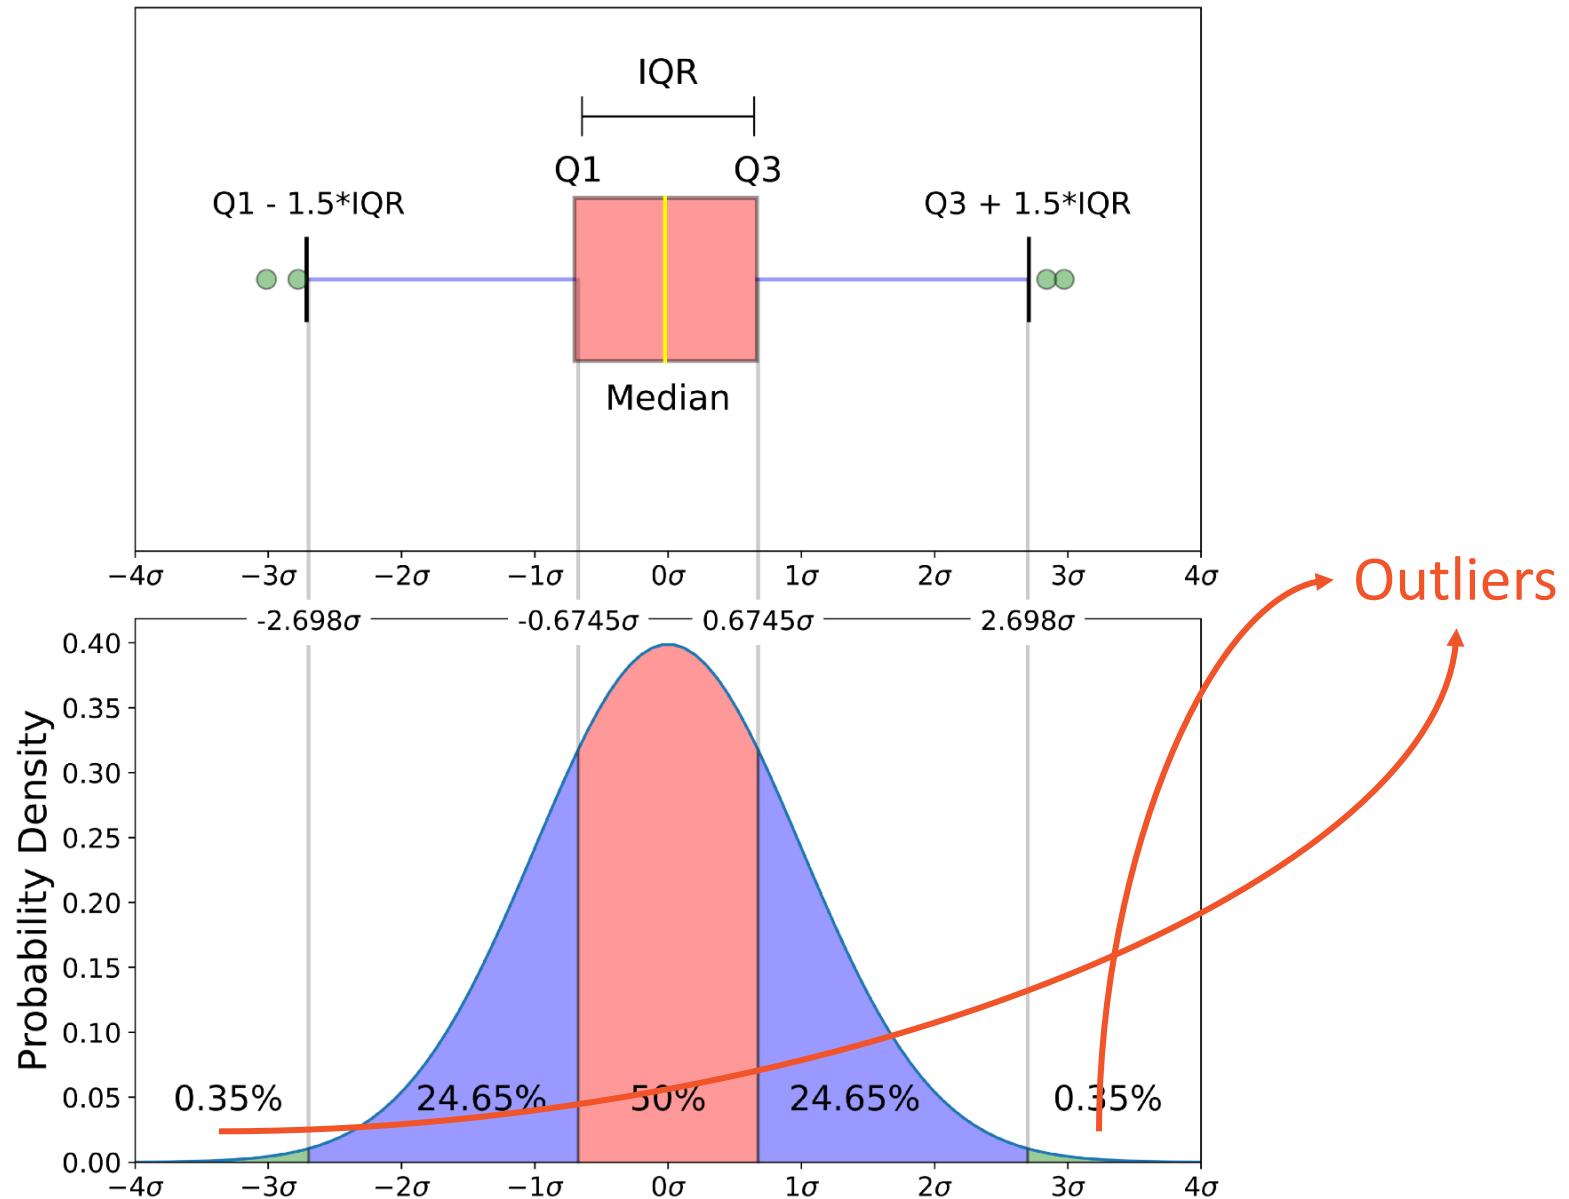
<https://s4be.cochrane.org/blog/2018/09/26/a-beginners-guide-to-standard-deviation-and-standard-error/#:~:text=Standard%20deviation%20tells%20you%20how,standard%20deviations%20of%20the%20mean.>

Pengenalan Box Plot



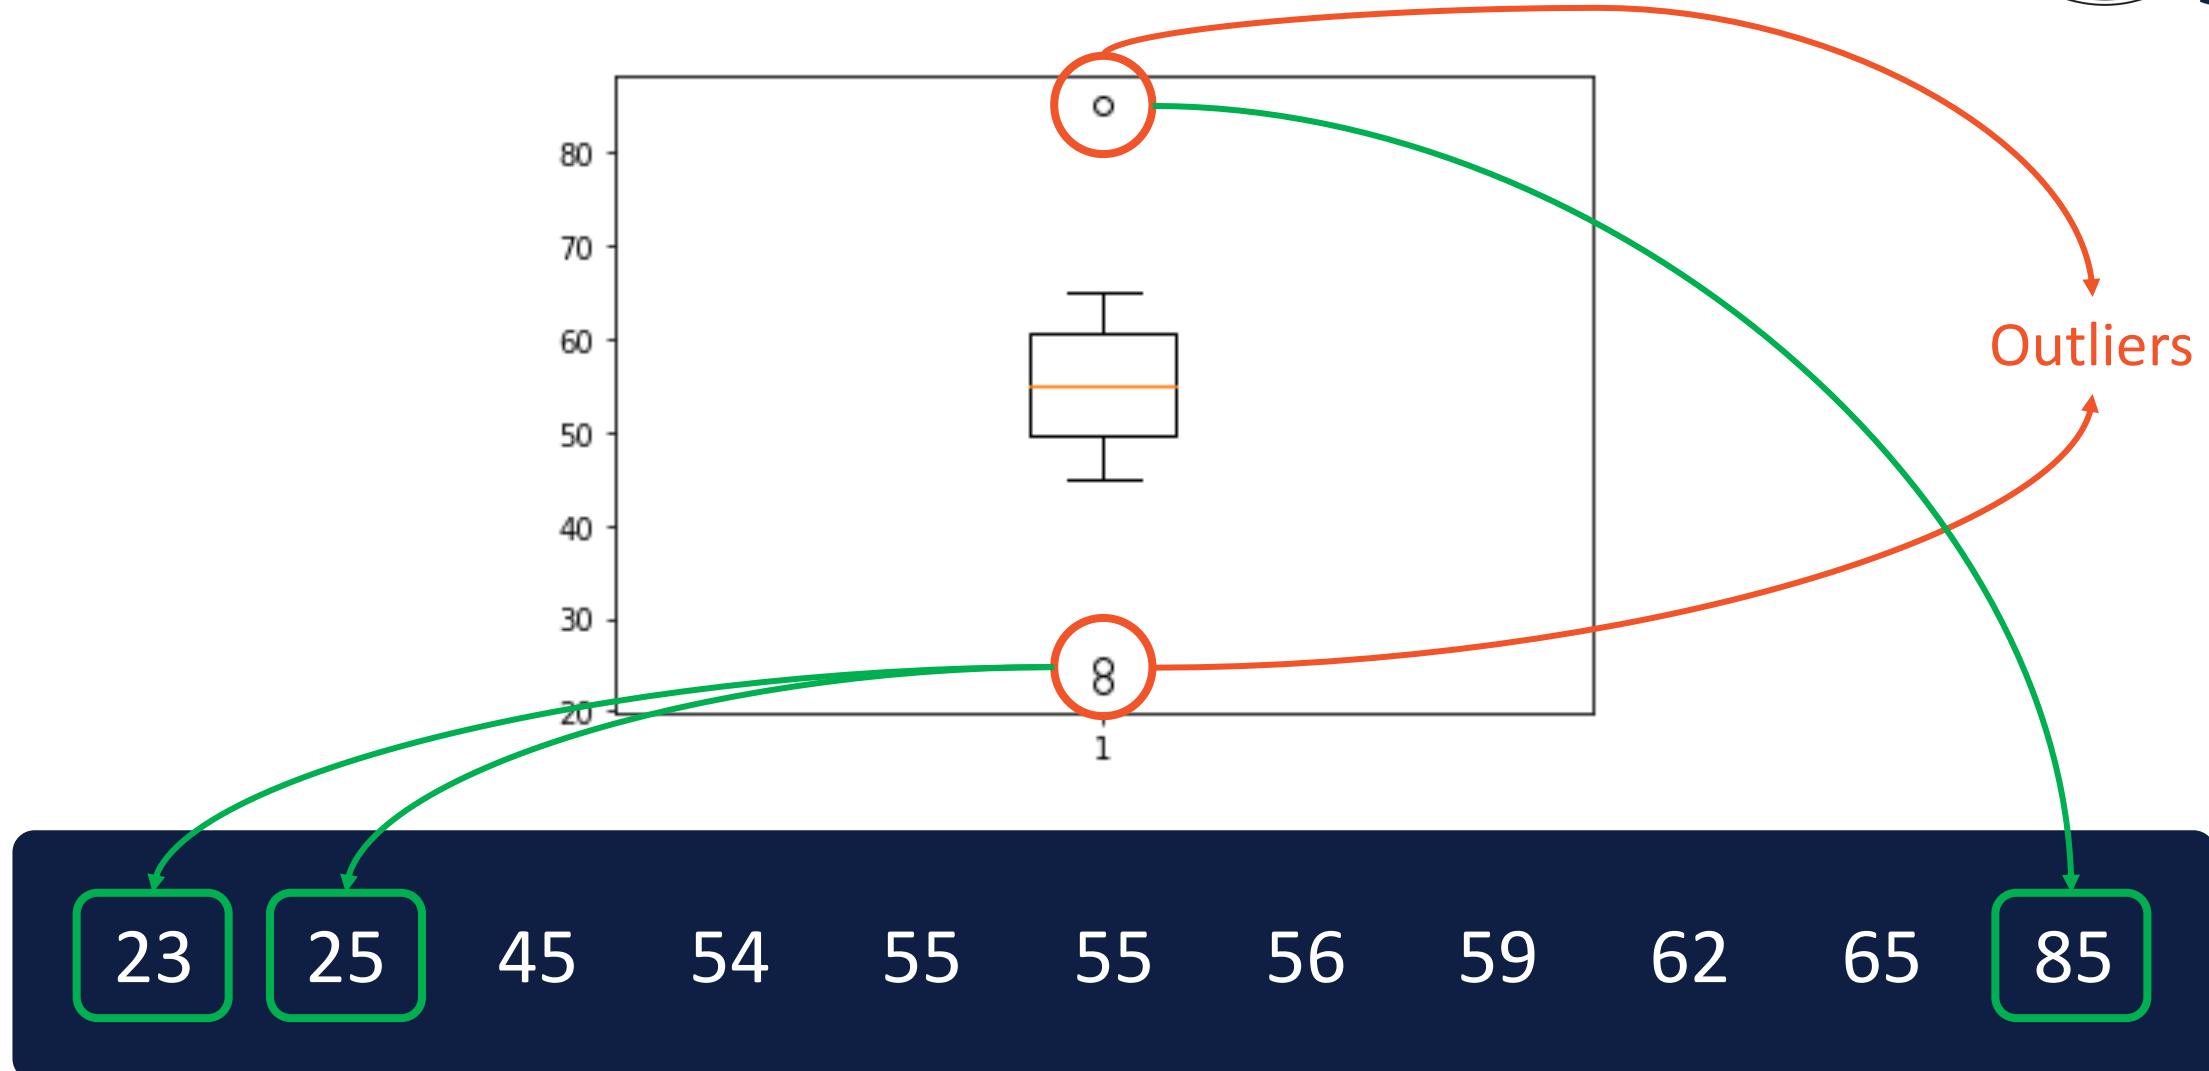
Sumber: <https://towardsdatascience.com/understanding-boxplots-5e2df7bcbd51#:~:text=A%20boxplot%20is%20a%20standardized,and%20what%20their%20values%20are.>

Box Plot Pada Distribusi Normal



Sumber: <https://towardsdatascience.com/understanding-boxplots-5e2df7bcfd51#:~:text=A%20boxplot%20is%20a%20standardized,their%20values%20are.>

Contoh Kasus Box Plot





Shifting dan Scaling

Bagaimana perubahan data mempengaruhi pemusatan dan penyebaran data

Shifting (Pergeseran)

Apa itu *shifting*?

Menggeser nilai pada kelompok data dengan cara **menambahkan** (+) atau **mengurangkan** (-) semua nilai pada kelompok data dengan nilai tertentu

Contoh 1

$$4, 5, 8, 12 \rightarrow +2 \rightarrow 6, 7, 10, 14$$

Contoh 2

$$4, 5, 8, 12 \rightarrow -2 \rightarrow 2, 3, 6, 10$$

Dampak Shifting (1)

Data Asli

4, 5, 8, 8, 12

Mean = 7.4

Median = 8

Modus = 8

Rentang = 8

IQR = 3

STD = 2.8

Data Shift

+2 → 6, 7, 10, 10, 14

Mean = 9.4

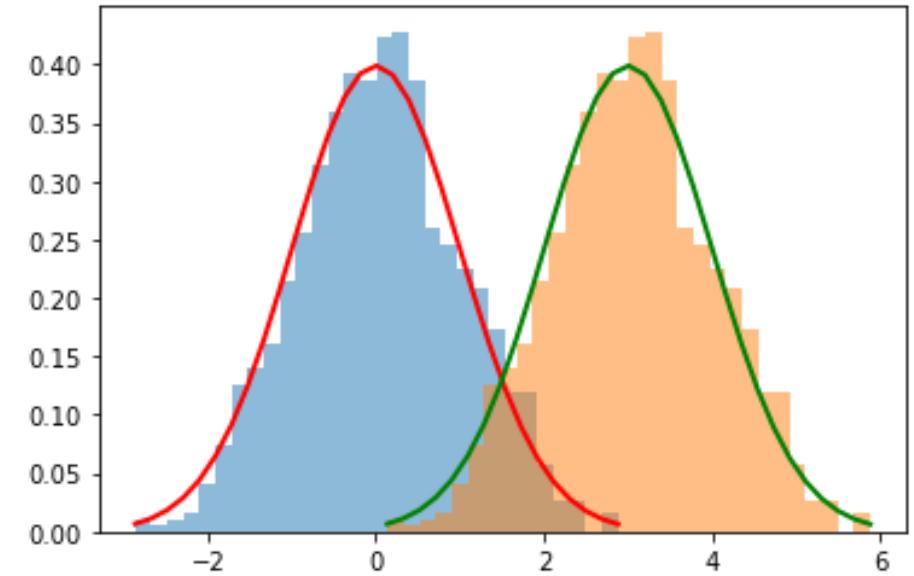
Median = 10

Modus = 10

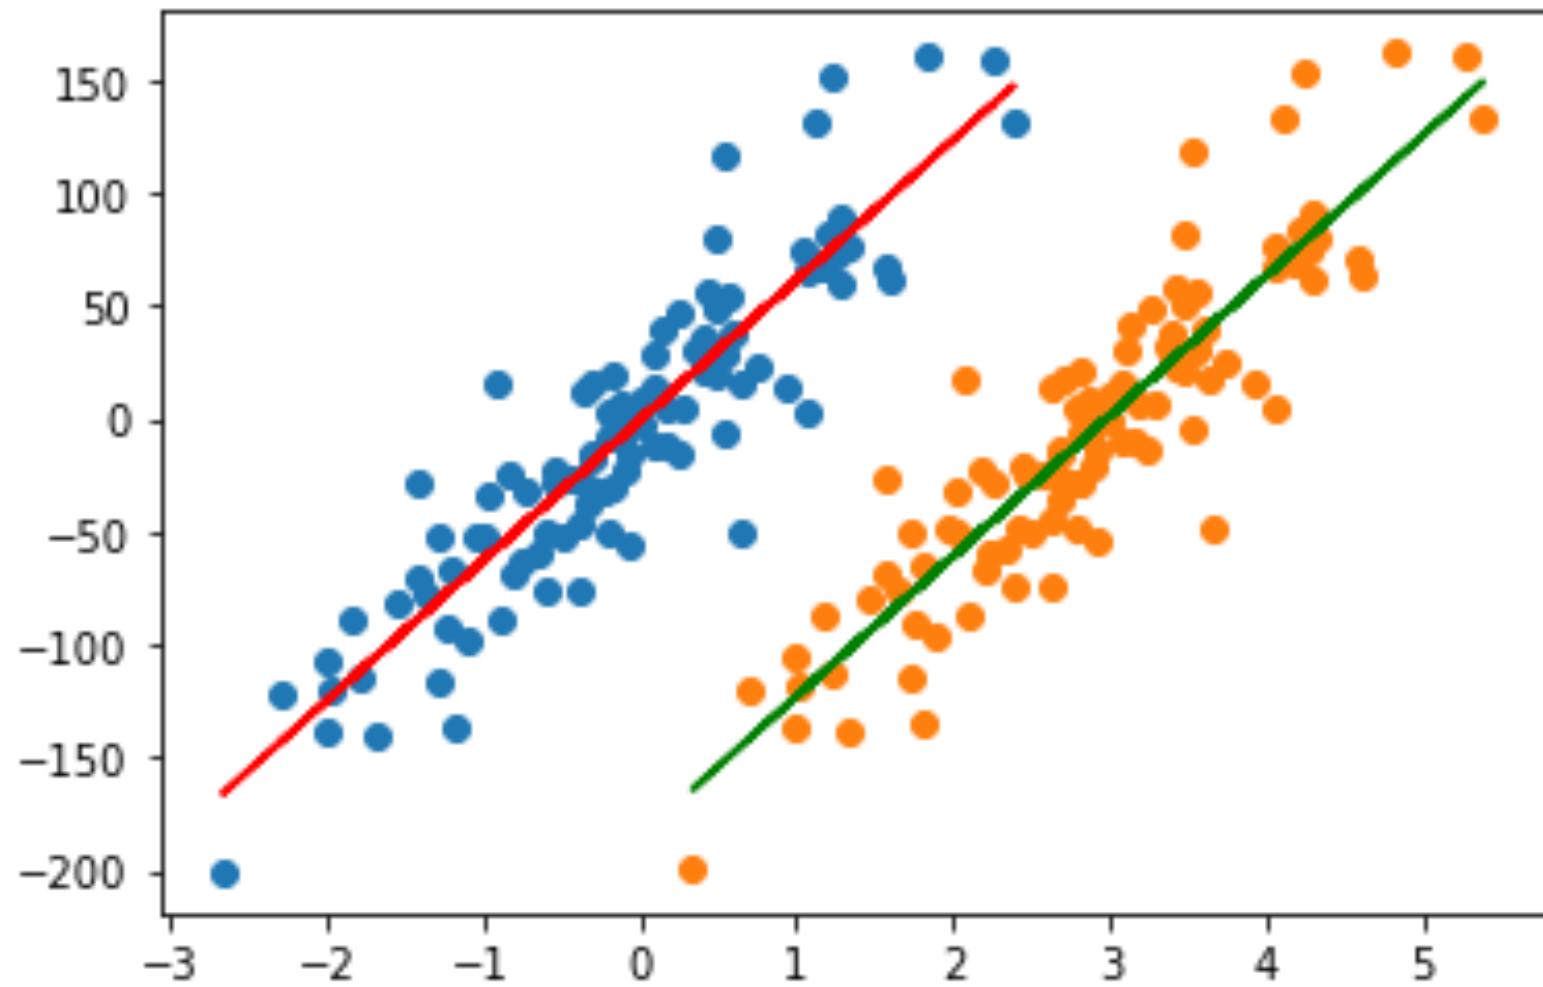
Rentang = 8

IQR = 3

STD = 2.8



Dampak Shifting (2) – Prior Shift di ML



Scaling (Penyekalaan)



Apa itu *scaling*?

Menyekalakan nilai pada kelompok data dengan cara **mengkalikan** atau **membagi** semua nilai pada kelompok data dengan nilai tertentu

Contoh 1

$$4, 5, 8, 12 \rightarrow \times 2 \rightarrow 8, 10, 16, 24$$

Contoh 2

$$4, 5, 8, 12 \rightarrow \div 2 \rightarrow 2, 2.5, 4, 6$$

Dampak Scaling

Data Asli

4, 5, 8, 8, 12

Mean = 7.4

Median = 8

Modus = 8

Rentang = 8

IQR = 3

STD = 2.8

Data Scale

$\times 2 \rightarrow 8, 10, 16, 16, 24$

Mean = 14.8

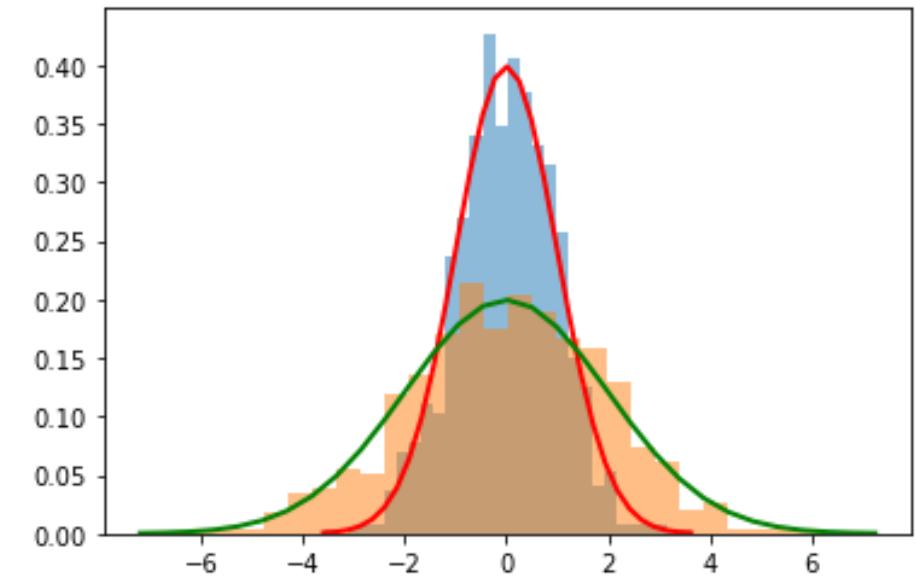
Median = 16

Modus = 16

Rentang = 16

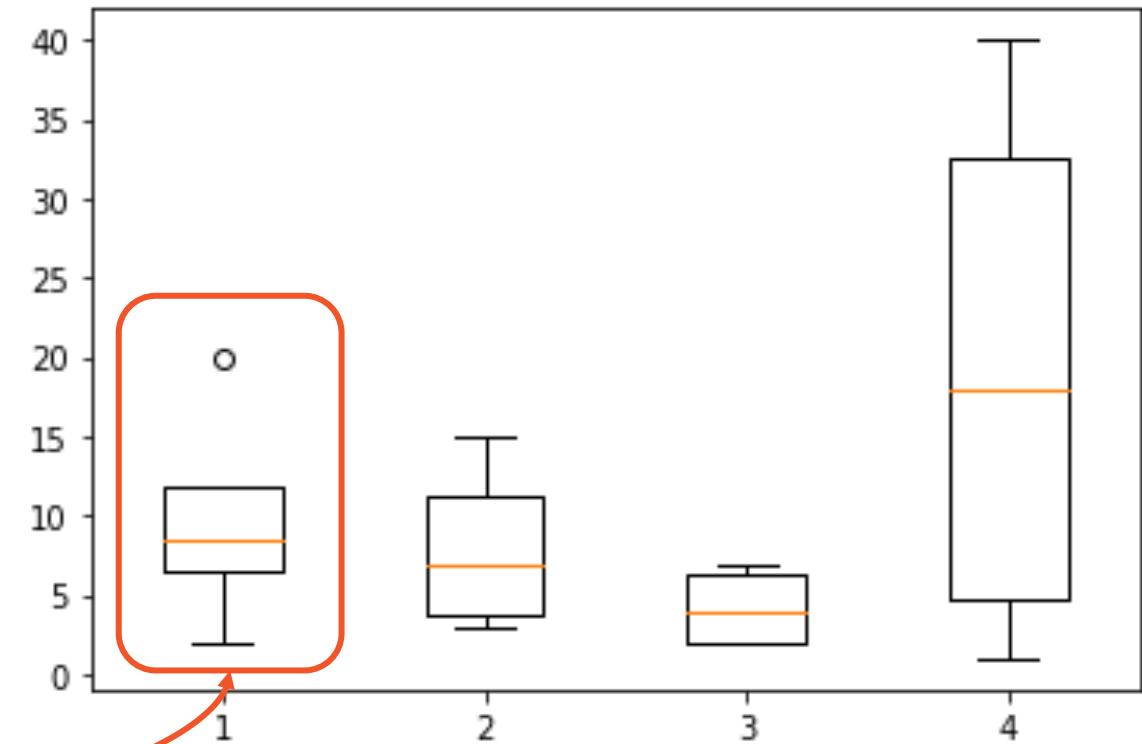
IQR = 6

STD = 5.6



Manfaat *Scaling* – Normalisasi Data (1)

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 data_raw = np.array([
5     [2, 3, 7, 30],
6     [9, 4, 6, 1],
7     [8, 15, 2, 40],
8     [20, 10, 2, 6]
9 ])
```

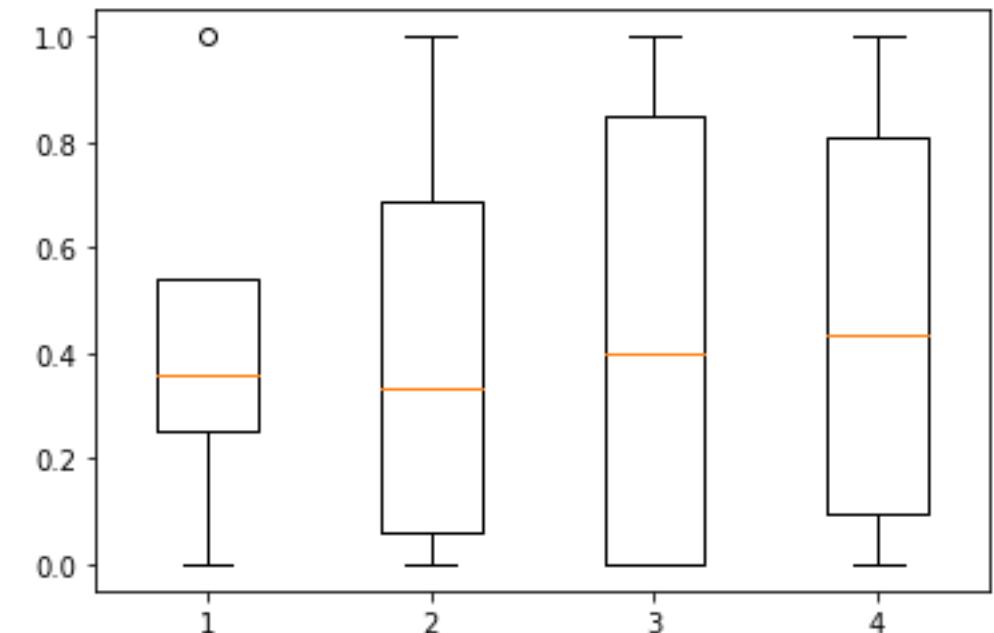


Dibaca secara kolom oleh matplotlib

Manfaat *Scaling* – Normalisasi Data (2)

```
1 # Normalisasi Dada - MinMax Scaler
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.preprocessing import MinMaxScaler
5
6 data_raw = np.array([
7     [2, 3, 7, 30],
8     [9, 4, 6, 1],
9     [8, 15, 2, 40],
10    [20, 10, 2, 6]
11 ])
12
13 scaler = MinMaxScaler()
14 data_scale = scaler.fit_transform(data_raw)
```

$$x_{norm} = \frac{x - \min(x)}{\max(x) - \min(x)}$$



Manfaat *Scaling* – Standarisasi Data

```

1 # Standarisasi Data
2 import numpy as np
3 import matplotlib.pyplot as plt
4 from sklearn.preprocessing import MinMaxScaler, StandardScaler
5
6 data_raw = np.array([
7     [2, 3, 7, 30],
8     [9, 4, 6, 1],
9     [8, 15, 2, 40],
10    [20, 10, 2, 6]
11 ])
12
13 stand = StandardScaler()
14 data_stand = stand.fit_transform(data_raw)
15
16 plt.boxplot(data_stand)

```

$$x_{stand} = \frac{x - \text{mean}(x)}{\text{std}(x)}$$

